



Data re-uploading for a universal quantum classifier

A. Perez-Salinas et al

weekly meeting
May 30, 2023



Klassische Klassifikation

- **Problem:** Anhand von wenigen Trainingsbeispielen soll ein Algorithmus durch beliebige Eingabe von Merkmalen (\vec{x}) eine eindeutige Zuordnung in eine Menge aus möglichen Klassen ($\{y_k\}_{k=0}^K$) treffen
- **Beispiele:** Spam, Tumorerkennung, Schweinsemotionen
- **Vorgehen:** Modellierung der Klassen über eine nichtlineare Funktion, z.B. logistische Funktion


$$h_{\vec{\theta}}^{(k)}(\vec{x}) = \frac{1}{1 + e^{-\vec{\theta} \cdot \vec{x}}} \quad \text{oder neuronale Netze}$$

und Bewertung der Qualität über eine Kostenfunktion, meist


$$C(\vec{\theta}) = -\frac{1}{M} \sum_{m=0}^M \sum_{k=0}^K \left[y_k^{(m)} \log \left(h_{\vec{\theta}}^{(k)}(\vec{x}^{(m)}) \right) + (1 - y_k^{(m)}) \log \left(1 - h_{\vec{\theta}}^{(k)}(\vec{x}^{(m)}) \right) \right]$$

Quanten-Klassifikation

- **Nachteile:** Daten können nur schwer ausgelesen (QPEA) und nicht gespeichert werden (No-Cloning Theorem)
- **Vorteile:** Daten können sehr effizient dargestellt werden (superdense coding) und bereits wenige Qubits können hohe Komplexität erzeugen
- **Idee:** Nutze Qubits für Repräsentation und klassischen Computer zur Optimierung eines neuronalen Netzes



(a) Neural network



(b) Quantum classifier



Umsetzung

- sogenannte layer gates $U(\vec{\phi}_i, \vec{x})$ encodieren zum einen Informationen über den Zustand ($\vec{x} \hat{=}$ Eingangsneuronen) und zum anderen eine nichtlineare Transformation ($\vec{\phi} \hat{=}$ hidden-layer)
- Messung legt vom Schaltkreis vorhergesagte Klasse entsprechend der Eingaben fest
- Anpassen der Parameter $\vec{\phi}$, um Kostenfunktion

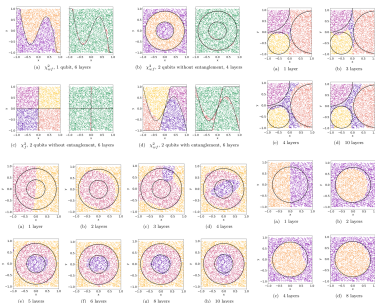
$$C(\phi) = \frac{1}{2M} \sum_{m=1}^M \left(\sum_{k=0}^K (|\langle \psi_k | \psi(\vec{\phi}) \rangle|^2 - y_c(\vec{x}_\mu))^2 \right)$$

zu minimieren.

- zusätzliche Qubits (und deren Verschränkung) helfen die Anzahl der nötigen layer gates zu reduzieren

Resultate


- Quanten-Klassifikatoren sind qualitativ mit (vermutlich sehr einfachen) klassischen ML-Methoden vergleichbar
- wenige Qubits reichen aus, um sehr gute Ergebnisse zu erreichen
- (ein weiteres erfolgreiches quanten-klassisches Hybridverfahren)



Problem	Classical classifiers		Quantum classifier	
	NN	SVC	χ_f^2	χ_{wf}^2
Circle	0.96	0.97	0.96	0.97
3 circles	0.88	0.66	0.91	0.91
Hypersphere	0.98	0.95	0.91	0.98
Annulus	0.96	0.77	0.93	0.97
Non-Convex	0.99	0.77	0.96	0.98
Binary annulus	0.94	0.79	0.95	0.97
Sphere	0.97	0.95	0.93	0.96
Squares	0.98	0.96	0.99	0.95
Wavy Lines	0.95	0.82	0.93	0.94

Das andere Blabla

- ein einzelnes Qubit kann (vermutlich) wie ein neuronales Netz jede Funktion beschreiben (**interessiert keinen**)
- L-BFGS-B-Verfahren liefert bessere Ergebnisse als Gradienten-Verfahren
(**wundert keinen**, macht für komplexe Probleme aber auch keinen Sinn, weil Approximationsverfahren für die Fisher-Metrik auch akzeptabel sind)
- Quantenalgorithmen sind gut bei krummlinigen Klassengrenzen; klassische ML Algorithmen können das nicht (**Na ja...**)



Implikationen für uns

- **man kann auch mit wenigen Qubits sehr gute Resultate erzielen**
- Quantum Brilliance behauptet diesen Algorithmus bereits sehr erfolgreich umgesetzt (**ähnliche Ergebnisse wie Simulator!**)
- Quanten Machine Learning erscheint als fruchtvolles Gebiet für erste Anwendungen von limitierter Hardware
- QPT oder Basiswechsel (nur $\pi/2^n$ -Pulse) zum Auslesen des Überlapps?
- **entangling mit CZ-gate!!!**
- Klassifizierung von Bildern: wie genau können Pulse generiert werden und Zustände ausgelesen werden?